

به نام خدا



دانشگاه تهران



دانشکده مهندسی برق و کامپیوتر

درس شبکه‌های عصبی و یادگیری عمیق

تمرین چهارم

610399205

امیرعباس رضا سلطانی

610399199

نیما نیرومند

فهرست

۱	قوانين
۱	پرسش ۱. تحلیل احساسات متن فارسی
۱	۱-۱. مجموعه داده
۱	۲-۱. پیش پردازش دادهها
۶	۳-۱. نمایش ویژگی
۷	۴-۱. ساخت مدل
۹	۵-۱. ارزیابی
۹	۶-۱. امتیازی
۱۰	پرسش ۲ - سامانه‌های سایبرفیزیکی: نگهداری هوشمند
۱۰	۱-۲. پیش پردازش دادهها
۱۱	۱-۱. مدل سازی و ارزیابی
۱۹	۱-۱. مقایسه با مدل‌های پایه‌ای

ج

قوانين

قبل از پاسخ دادن به پرسش‌ها، موارد زیر را با دقت مطالعه نمایید:

- از پاسخ‌های خود یک گزارش در قالبی که در صفحه‌ی درس در سامانه‌ی Elearn با نام **REPORTS_TEMPLATE.docx** قرار داده شده تهیه نمایید.
- پیشنهاد می‌شود تمرين‌ها را در قالب گروه‌های دو نفره انجام دهید. (بیش از دو نفر مجاز نیست و تحويل تک نفره نیز نمره‌ی اضافی ندارد) توجه نمایید الزامی در یکسان ماندن اعضای گروه تا انتهای ترم وجود ندارد. (یعنی، می‌توانید تمرين اول را با شخص A و تمرين دوم را با شخص B و ... انجام دهید)
- **کیفیت گزارش شما در فرآیند تصحیح از اهمیت ویژه‌ای برخوردار است؛** بنابراین، لطفاً تمامی نکات و فرض‌هایی را که در پیاده‌سازی‌ها و محاسبات خود در نظر می‌گیرید در گزارش ذکر کنید.
- در گزارش خود مطابق با آنچه در قالب نمونه قرار داده شده، برای شکل‌ها زیرنویس و برای جدول‌ها بالانویس در نظر بگیرید.
- الزامی به ارائه توضیح جزئیات کد در گزارش نیست، اما باید نتایج بدست آمده از آن را گزارش و تحلیل کنید.
- **تحلیل نتایج الزامی می‌باشد، حتی اگر در صورت پرسش اشاره‌ای به آن نشده باشد.**
- **دستیاران آموزشی ملزم به اجرا کردن کدهای شما نیستند؛** بنابراین، هرگونه نتیجه و یا تحلیلی که در صورت پرسش از شما خواسته شده را به طور واضح و کامل در گزارش بیاورید. در صورت عدم رعایت این مورد، بدیهی است که از نمره تمرين کسر می‌شود.
- کدها حتماً باید در قالب نوت‌بوک با پسوند **.ipynb** تهیه شوند، در پایان کار، تمامی کد اجرا شود و خروجی هر سلول حتماً در این فایل ارسالی شما ذخیره شده باشد. بنابراین برای مثال اگر خروجی سلولی یک نمودار است که در گزارش آورده‌اید، این نمودار باید هم در گزارش هم در نوت‌بوک کدها وجود داشته باشد.
- در صورت مشاهده‌ی تقلب امتیاز تمامی افراد شرکت‌کننده در آن، **100 - لحظ می‌شود.**
- تنها زبان برنامه نویسی مجاز **Python** است.
- استفاده از کدهای آماده برای تمرين‌ها به هیچ وجه مجاز نیست. در صورتی که دو گروه از یک منبع مشترک استفاده کنند و کدهای مشابه تحويل دهند، تقلب محسوب می‌شود.

نحوه محاسبه تاخیر به این شکل است: پس از پایان رسیدن مهلت ارسال گزارش، حداکثر تا یک هفته امکان ارسال با تاخیر وجود دارد، پس از این یک هفته نمره آن تکلیف برای شما صفر خواهد شد.

- سه روز اول: بدون جریمه
- روز چهارم: ۵ درصد
- روز پنجم: ۱۰ درصد
- روز ششم: ۱۵ درصد
- روز هفتم: ۲۰ درصد

حداکثر نمره‌ای که برای هر سوال می‌توان اخذ کرد ۱۰۰ بوده و اگر مجموع بارم یک سوال بیشتر از ۱۰۰ باشد، در صورت اخذ نمره بیشتر از ۱۰۰، اعمال نخواهد شد.

برای مثال: اگر نمره اخذ شده از سوال ۱ برابر ۱۰۵ و نمره سوال ۲ برابر ۹۵ باشد، نمره نهایی تمرین ۹۷.۵ خواهد بود و نه ۱۰۰.

لطفاً گزارش، کدها و سایر ضمایم را به در یک پوشه با نام زیر قرار داده و آن را فشرده سازید، سپس در سامانه‌ی Elearn بارگذاری نمایید:

HW[Number]_[Lastname]_[StudentNumber]_[Lastname]_[StudentNumber].zip

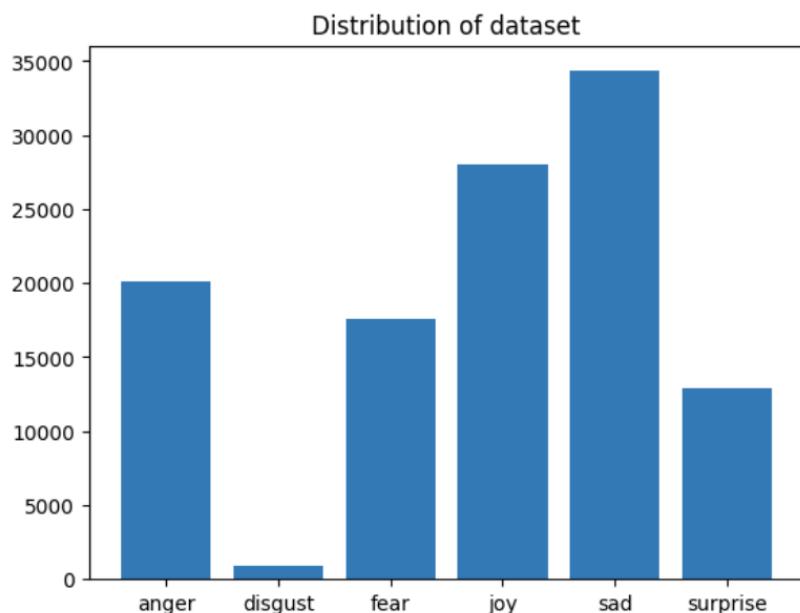
(مثال: HW1_Ahmadi_810199101_Bagheri_810199102.zip)

برای گروه‌های دو نفره، بارگذاری تمرین از جانب یکی از اعضا کافی است ولی پیشنهاد می‌شود هر دو نفر بارگذاری نمایند.

پرسش 1. تحلیل احساسات متن فارسی

۱-۱. مجموعه داده

مجموعه داده شاما توییت هایی از اپیکیشن توییتر(ایکس فعلی) می باشد که احساسات توییت‌ها را در نظر گرفته است و بر این اساس ۱۱۳۸۲۹ توییت را به ۶ کلاس anger, disgust, fear, joy, sad, surprise توزیع کرده است. که نشان‌دهنده احساسات آن توییتر است تقسیم شده‌اند حال توزیع این ۶ کلاس را بررسی می‌کنیم.



شکل 1. توزیع آماری کلاس‌های مجموعه داده

که همانطور که می‌بینیم توزیع کلاس‌ها متوازن نیست و برای معیارهای ارزیابی آن را در نظر باید بگیریم.

۱-۲. پیش‌پردازش داده‌ها

متن یکی از توییت‌ها در نظر می‌گیریم و پس از هر مرحله آن را خروجی می‌دهم دوباره

متن نمونه: ”آره منو ول کرده سراغ بچه خودش رفته 😊😊😊
وای اوایل اینقدر به همسرش و بچه اش حسودی میکردم همیشه اخم داشتم 😊
آره دقیقا
ولی فقط برای کسایی که دوستشون دارم بقیه آدما برام مهم نیستن

♥
Yugyeom
GOT7
유겸#
“갓세븐#”

از آنجایی که لینکها (که گاهی مربوط به تصویر و فیلم هستند) به خودی خود به درد ما نمی‌خورند پس url(با استفاده از رجکس آن) و html (با استفاده از beautishop در کتابخانه bs4) حذف می‌کنیم

متن نمونه: ”آره منو ول کرده سراغ بچه خودش رفته 😊😊😊
وای اوایل اینقدر به همسرش و بچه اش حسودی میکردم همیشه اخم داشتم 😊
آره دقیقا
ولی فقط برای کسایی که دوستشون دارم بقیه آدما برام مهم نیستن

♥
Yugyeom
GOT7
유겸#
“갓세븐#”

در ادامه کلماتی مانند خووب که یک حرف بیشتر از یکبار تکرار شده است(فرض کردم که کلمه‌ای نداریم که حرفی در آن بیش از یک بار تکرار شده باشد و تنها نمونه‌ای از آن که به ذهنم آمد داود بود که اونم چون اسمه تاثیری نداره آنچنان) برای این کار با استفاده از نوشته رجکس این کلمات و جایگزینی با حالت حرف شده آن‌ها این کار را انجام دادم

متن نمونه：“آره منو ول کرده سراغ بچه خودش رفته 😊

وای اوایل اینقدر به همسرش و بچه اش حسودی میکردم همیشه اخم داشتم 😊

آره دقیقا

ولی فقط برای کسای که دوستشون دارم بقیه آدما برام مهم نیستن



Yugyeom

GOT7

유겸#

“갓세븐#

حال به سراغ ایموجی‌ها می‌رویم که معنای مهمی دارند مخصوصاً برای تحلیل احساسات به این منظور با استفاده از کتابخانه emoji معادل فارسی ایموجی‌ها در فارسی را می‌نویسم.

متن نمونه：“آره منو ول کرده سراغ بچه خودش رفته :روده_بر:

وای اوایل اینقدر به همسرش و بچه اش حسودی میکردم همیشه اخم داشتم :روده_بر:

آره دقیقا

ولی فقط برای کسای که دوستشون دارم بقیه آدما برام مهم نیستن

:قلب_زرد:

Yugyeom

GOT7

유겸#

“갓세븐#

سپس متن را نرمال و توکن توکن می‌کنم و توکن‌هایی که کمتر از ۳ حرف دارند را استاپ ورد در نظر می‌گیرم و حذف می‌کنم و سپس توکن‌ها را به هم می‌چسبانم

حال به سراغ **stopword** ها میروم که کلماتی هستند که ارزش معنایی خاصی ندارند مانند در، از، به و فقط باعث طولانی تر شدن و همچنین کاهش دقت ما می‌شوند در صورت حضورشون پس به این منظور همشون رو حذف می‌کنم

متن نمونه：“آره من کرده سراغ بچه خدش رفته رده_بر ای ایل اینقدر همسرش بچه‌اش حسدی می‌کرم همیشه اخم داشتم رده_بر آره دقیقاً لی فقط برای کسای دشن دارم بقیه آدمابرام مهم نیستن قلب_زرد **yugyeom got** 갓세븐 ”

و در نهایت به سراغ ریشه کلمات می‌رویم برای مثلاً رفتم، رفت، رفته همشون یک ریشه دارند و ما دوست داریم که توکن‌هایمان یکی باشند تا حد ممکن تا دقیق تر بتوانیم بررسی کنیم (جای اینکه که توکن‌های با معنی یکسان فرم‌ها مختلف داشته باشند و جداگانه تلقی شوند در محاسبات) و همه کلمات را به ریششون تبدیل می‌کنیم.

متن نمونه：“آره من کرده سراغ بچه خد رفته رده_بر ایل اینقدر همسر بچه حسد می‌کرد همیشه اخ دا رده_بر آره دقیقاً ل فقط برای کسا دشن دار بقیه آدمابرا مه نیستن قلب_زرد **yugyeom got** 갓세븐 ”

۱-۳. نمایش ویژگی

از آنجایی که در شبکه داده‌های ورودی و خروجی ما عددی باید باشند و اما در تحلیل متن داده‌های ما متن هستند پس برای آموزش آن‌ها در وهله نخست باید سعی کنیم آن‌ها را به داده عددی تبدیل کنیم از آنجایی که داده‌های متنی به شکل دنباله‌ای هستند و ترتیب در آن‌ها حائز اهمیت می‌باشد پس ما باید آنها در بخش‌های کوچکتری یا همان توکن ببینیم پس با استفاده از ParsBERT جملات را تبدیل به برداری از توکن‌ها (به صورت عددی) می‌کنیم اما از آنجایی که میخواهیم طول جملات برای ورودی به شبکه یکسان باشد پس آن‌ها را به طول ۳۲ نگه میداریم (اگر کمتر از ۳۲ بود صفر گذاشته می‌شود)

سپس می‌خواهیم که هر کدام از این توکنا معنی دار باشند و آن‌ها را با یک بردار نشان دهیم که هر بردار نشان دهنده یک توکن باشد و انتظار داریم که بردار توکن‌ها نزدیک به هم مانند کتاب و مجله به هم نزدیک باشند یا اینکه جام به فوتبال و شذاب نزدیک باشد اما از کولر دور باشد همچنین مثلاً فاصله مرد و زن تقریباً برابر شاه و ملکه باشد با چنین تفکری در ParsBERT کلمات به شکل بردار تبدیل می‌کنیم

که خروجی آن ۷۶۸ می باشد یعنی اندازه بردار ویژگی هر توکن ۷۶۸ است اما خوب برای کار با شبکه بزرگ است پس می خواهیم کاهش بعد بدھیم و آن را به ۱۲۰ تبدیل کنیم.

۴-۱. ساخت مدل

می دانیم که ویژگی هایی از شبکه را که خودمون به مدل می دهیم را هایپر پارامتر می نامیم که یعنی برای آنها الگوریتم یادگیری وجود ندارد اما تنظیم آنها از مهم ترین قسمت آموزش یک شبکه عصبی می باشد در اینجا با استفاده از جستجوی شبکه ای (Grid search) می خواهیم ترکیب های مختلفی از هایپر پارامترها را تست و آنکه بهترین عملکرد را داشته انتخاب کنیم که ۲ تا برای اندازه دسته، ۲ تا برای بهینه ساز و ۲ تا برای طول گام در نظر گرفتیم و در مجموعه ۸ حالت داریم

حال یک مدل CNN-LSTM را به شکل زیر تعریف می کنیم

Layer (type)	Output Shape	Param #
conv1d_2 (Conv1D)	(None, 30, 32)	11,552
conv1d_3 (Conv1D)	(None, 28, 32)	3,104
max_pooling1d_1 (MaxPooling1D)	(None, 14, 32)	0
lstm_2 (LSTM)	(None, 14, 100)	53,200
lstm_3 (LSTM)	(None, 14, 100)	80,400
spatial_dropout1d_1 (SpatialDropout1D)	(None, 14, 100)	0
flatten (Flatten)	(None, 1400)	0
dense (Dense)	(None, 100)	140,100
dense_1 (Dense)	(None, 6)	606

شکل ۲. ساختار مدل CNN-LSTM

حال برای هر کدام از ۸ حالت ران میکنیم(متاسفانه به علت کمبود منابع و طولانی بودن مراحل تعداد ایپاکها ۵ در نظر گرفته شده است) که بررسی میشود بهترین پاسخ در دقت و F1 (macro avg) حالتیه که بهینه ساز ما آدام و اندازه دسته ها ۸ و طول گام 0.001 باشد

حال مدل های CNN و LSTM را میسازیم و با این پارامترها ران میکنیم

Layer (type)	Output Shape	Param #
lstm_5 (LSTM)	(None, 32, 100)	88,400
lstm_6 (LSTM)	(None, 32, 100)	80,400
spatial_dropout1d_2 (SpatialDropout1D)	(None, 32, 100)	0
flatten_1 (Flatten)	(None, 3200)	0
dense_2 (Dense)	(None, 100)	320,100
dense_3 (Dense)	(None, 6)	606

شکل ۳. ساختار مدل LSTM

Layer (type)	Output Shape	Param #
conv1d_4 (Conv1D)	(None, 30, 32)	11,552
conv1d_5 (Conv1D)	(None, 28, 32)	3,104
max_pooling1d_2 (MaxPooling1D)	(None, 14, 32)	0
spatial_dropout1d_3 (SpatialDropout1D)	(None, 14, 32)	0
flatten_2 (Flatten)	(None, 448)	0
dense_4 (Dense)	(None, 100)	44,900
dense_5 (Dense)	(None, 6)	606

شکل ۴. ساختار مدل CNN

حال میدانیم که CNN برای پیدا کردن ویژگی به درد می خورد و چون داده ما متن هست لایه های کانولوشن را یک بعدی میگیریم و از سوی دیگر LSTM ترتیب بین ویژگی را تاثیر میدهد و بررسی

میکند بر اساس قبلی و بعدی‌ها چطور هست پس با ترکیب این دو می‌توانیم از ویژگی‌های هردو بهره‌مند شویم

۱-۵. ارزیابی

accuracy	f1-score	recall	precision	
0.69	0.68	0.52	0.76	CNN-LSTM
0.62	0.60	0.55	0.71	CNN
0.50	0.38	0.37	0.45	LSTM

جدول ۱. ارزیابی مدل‌ها

بررسی می‌شود همانطور که انتظار داشتیم CNN-LSTM عملکرد بهتری را داشته هست همین طور معیارهای واردۀ از نوع macro هستند چرا که میانگین معمولی بین کلاس‌ها است و بین کلاس‌ها ارزش یکسانی قائل است و با توجه به اینکه داده‌ها نامتوازن بهترین انتخاب می‌باشد (چون در حالت وزن دار میانگین وزن دار بر اساس تعداد نمونه‌ها هر کلاس است) (و به تعداد کلاس‌هایی که نمونه بیشتری دارند وزن بیشتری میده) و طبق انتظار چون نا متوازنیم اگر همه را آن کلاس معرفی کنیم اعداد بالا می‌شوند که درست نیست و در micro وزن بین تمام نمونه‌ها حساب می‌شود که در این حالت کلاسی که بیشتر نمونه دارد تاثیر بیشتری دارد و در داده‌های نامتوازن به درد نمی‌خورد)

۱-۶. امتیازی

جدول ۲. ارزیابی مدل‌های کلاسیک

accuracy	f1-sco	recall	precision	
0.69	0.68	0.52	0.76	CNN-LSTM
0.62	0.6	0.55	0.71	CNN
0.50	0.38	0.37	0.45	LSTM
0.5	0.46	0.5	0.75	NB
0.92	0.92	0.92	0.92	SVM

0.89	0.87	0.87	0.88	LR
------	------	------	------	----

روش کیسه کلمات به این شکل است که ترتیب به کلمات رو ارزشی براش نمیدونیم و فقط برآمده مهمه چه کلماتی و چندبار آمده است و از جدول tf-idf استفاده میکنیم که بیانگر تعداد تکرار ترم در یک متن در لگاریتم(تعداد کل داکیومنتها در تعداد داکیومنتهایی که ترم آمده) پس هرچی بیشتر باشه ترم ارزشمند تره و بر این اساس برای هر یک ارزشی قائل میشیم و داکومنتها را بر اساس برداری بر اساس ترم مینویسیم (در اینجا به علت کمبود منابع ۱۰ درصد داده‌ها گرفته شده اند) و سه روش زیر را روی آنها پیاده می‌کنیم.

پرسش ۲ – سامانه‌های سایبرفیزیکی: نگهداری هوشمند

۱-۲. پیش پردازش داده‌ها

انتخاب داده‌ها: داده‌ها به دو دسته آموزش و تست تقسیم می‌شوند. داده‌های آموزش دارای 20631 سطر و داده‌های تست دارای 13096 سطر هستند. هر سطر دارای 26 ویژگی است. 3 ویژگی مربوط به operational setting، 21 ویژگی مربوط به sensor measurement است، یک ویژگی شماره موتور و یک ویژگی زمان اطلاعات ثبت شده در دوره است.

ابتدا ستون‌های s19, s16, s10, s5, s1, c3 را با توجه به اینکه variation بالایی با افزایش cycle ندارند از داده‌ها حذف می‌کنیم. ویژگی‌ها مدنظر برای ورودی شبکه، متشكل از 16 operational setting و 2 sensor measurement است.

نرمال سازی داده‌ها: از آنجا که داده‌ها از حدود متفاوتی هستند و هر سنسور در مقیاس متفاوت داده ثبت می‌کند و همچنین مقیاس operational setting ها با

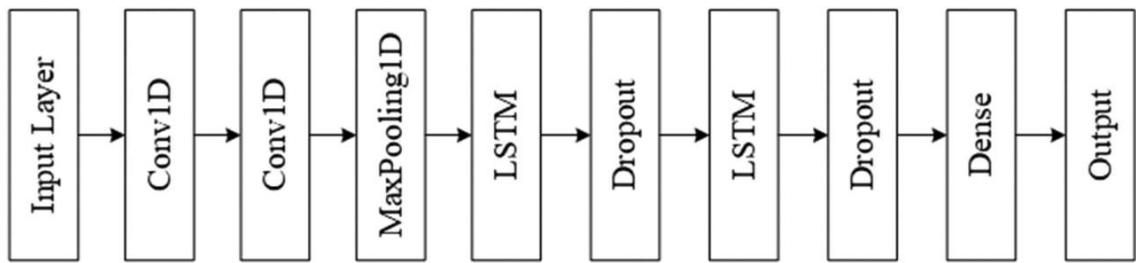
یکدیگر و با مقیاس سنسورها متفاوت است، با استفاده از min-max scaler روی هر ویژگی، آن ها را به بازه ۰ تا ۱ منتقل می کنیم.

برچسب زنی داده ها: برای مساله regression، ابتدا شماره آخرین cycle مربوط به هر موتور را استخراج کرده و سپس، به ازای هر سطر از داده ها، مقدار cycle آن سطر را از مقدار ماکریموم بدست آمده از موتور مربوط به آن سطر را کم می کنیم و از این داده به عنوان داده هدف (RUL) استفاده می کنیم. این عملیات را برای داده آموزش انجام می دهیم. برای داده تست، پس از یافتن مقدار ماکریموم، مقدار RUL مربوط به هر موتور در فایل RUL_FD001 را به این مقادیر بیشینه اضافه می کنیم و مانند عملیات برای داده آموزش، ادامه مراحل را پی می گیریم. درواقع داده بدست آمده نشان دهنده زمان باقی مانده از عمر دستگاه است.

برای مساله classification، درصورتی که RUL (زمان باقی مانده از عمر دستگاه) بدست آمده دستگاه در مرحله قبل از ۵۰ کمتر باشد، دستگاه خراب (خروجی ۰) و در غیر این صورت دستگاه سالم (خروجی ۱) تلقی می شود

پردازش پنجره زمانی: برای آماده کردن داده ورودی برای شبکه، از مفهوم TimeWindow استفاده می کنیم. به این معنا که هر ورودی شبکه، ماتریس 18×30 است که ۱۸ تعداد ویژگی های جدول و ۳۰ اندازه پنجره است. درواقع ورودی نام، از سطر i تا سطر $i+30$ جدول است. خروجی نیز به ازای داده نام برای مساله regression، RUL بدست آمده برای سطر $i+30$ است. به این مفهوم که شبکه درصورت دیدن توالی ۳۰ نایابی TimeWindow، باید زمان باقی مانده از عمر دستگاه را پیش بینی کند. خروجی classification نیز، وضعیت دستگاه در آخرین سطر TimeWindow ($i+30$) است.

2-2. مدل سازی و ارزیابی



شکل ۵. ساختار شبکه LSTM-CNN

الف) classification

Precision نشان دهنده این است که چه درصدی از پیش بینی مدل از یک کلاس معین درست بوده است. Recall نشان دهنده این است که مدل چه درصدی از داده های یک کلاس را به درستی تشخیص داده است. Accuracy دقت کلی مدل در پیش بینی برچسب هارا نشان می دهد. F1-Score نشان دهنده میانگین هARMONIK بین Precision و Recall است. این نوع میانگین وقتی که داده های ورودی از مقیاس های متفاوتی هستند، دقت بهتری نسبت به میانگین حسابی دارد. همچنین مساحت زیر نمودار (AUC) ROC بیانگر قدرت تفکیک مدل بین داده های کلاس ۰ و ۱ است. همه مقادیر مذکور مقادیر بین ۰ و ۱ دارند. مقادیر بزرگتر نشان از بهتر بودن مدل در هر معیار دارد.

جدول ۱ . مشخصات مدل Classification برای مساله LSTM-CNN

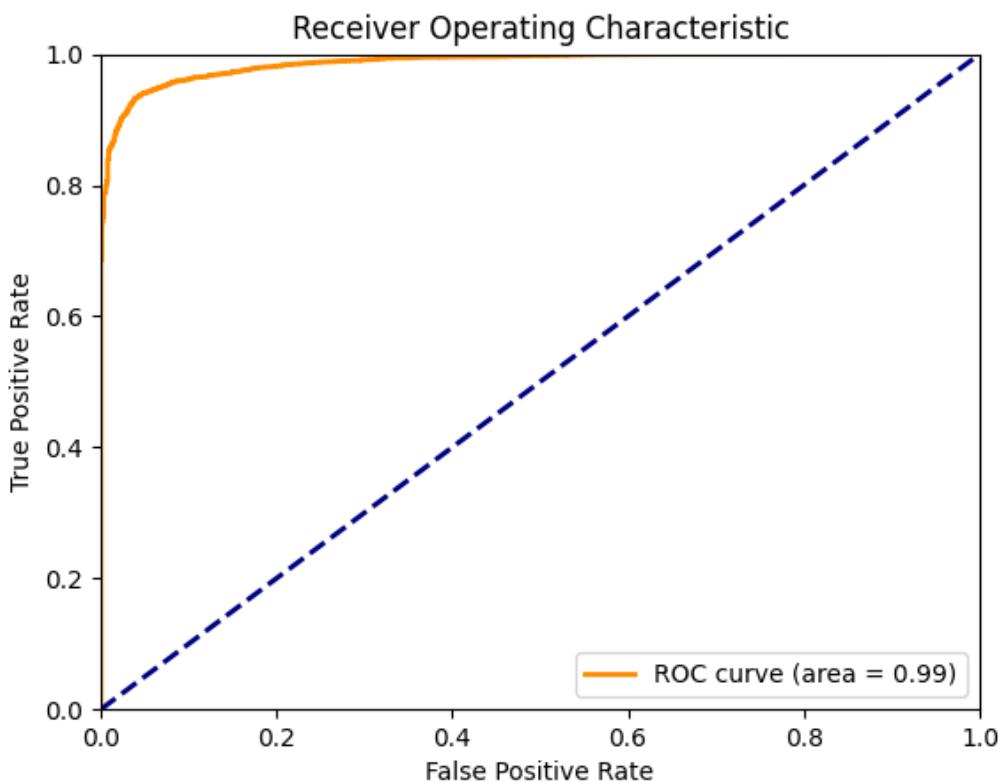
BatchSize	200
Epochs	200
Optimizer	Adam
Loss	BinaryCrossEntropy

• بدون EarlyStopping

جدول 2. نتایج مدل Classification برای LSTM-CNN بدون EarlyStopping

	Class 0 (Unhealthy)	Class 1 (Healthy)

F1_Score	0.80	0.98
Accuracy	0.96	0.96
Precision	0.78	0.98
Recall	0.82	0.98



شکل ۶. نمودار ROC برای مدل Classification LSTM CNN برای مساله EarlyStopping بدون

جدول ۳. ماتریس درهمیریختگی برای مدل Classification LSTM CNN برای مساله EarlyStopping بدون

	Class 0 (Unhealthy)	Class 1(Healthy)
Class 0(Unhealthy)	730	156
Class 1(Happy)	202	9108

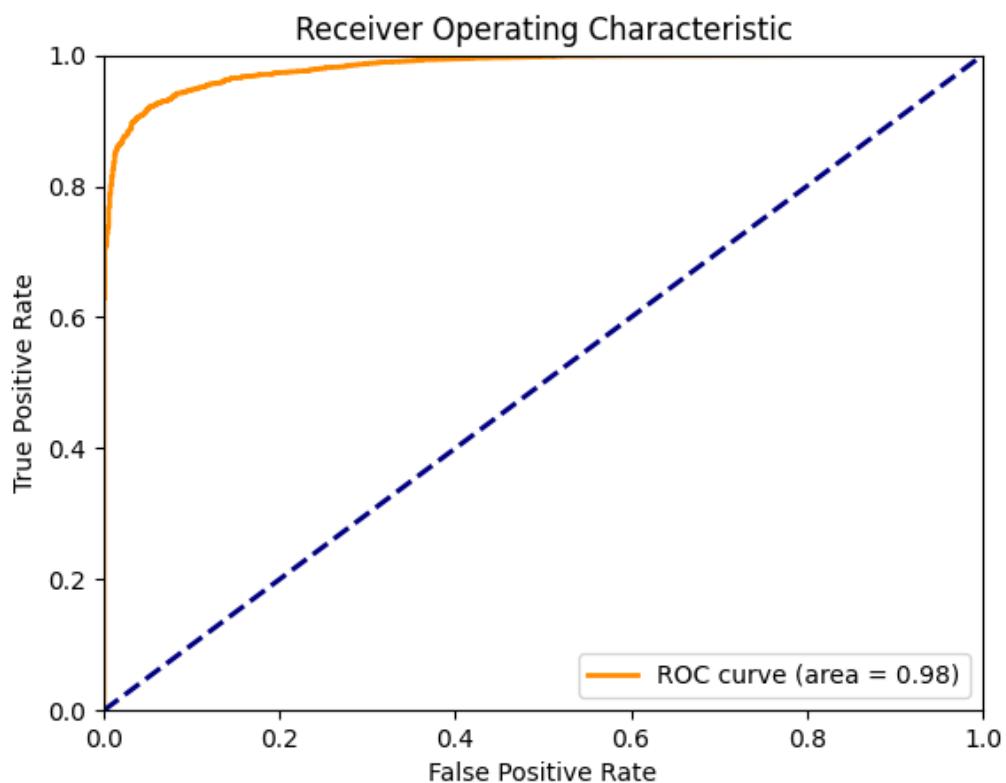
دقت کلی مدل 96 درصد است. 78 درصد از پیش بینی ها برای کلاس 0، درست است و این مقدار برای کلاس 1، 98 درصد است. همچنین 82 درصد از داده های غیرسالم واقعی (grandtruth) را به درستی

تشخیص داده است. این مقدار برای داده های سالم، 98 درصد است. همچنین توانایی مدل در تمایز بین داده های دسته 1 و دسته 0، 98 درصد است (با توجه به AUC).

- استفاده از EarlyStopping

جدول 4. نتایج مدل با Classification LSTM CNN برای EarlyStopping

	Class 0 (Unhealthy)	Class 1 (Healthy)
F1_Score	0.76	0.97
Accuracy	0.96	0.96
Precision	0.79	0.97
Recall	0.73	0.98



شکل 7. نمودار ROC برای مدل LSTM CNN برای مساله Classification با EarlyStopping

جدول 5. ماتریس درهم ریختگی برای مدل LSTM CNN برای مساله Classification با

EarlyStopping

	Class 0 (Unhealthy)	Class 1(Healthy)
Class 0(Unhealthy)	649	237
Class 1(Healthy)	168	9142

دقت کلی مدل 96 درصد است. 79 درصد از پیش بینی ها برای کلاس 0، درست است و این مقدار برای کلاس 1، 97 درصد است. همچنین 73 درصد از داده های غیرسالم واقعی (grandtruth) را به درستی تشخیص داده است. این مقدار برای داده های سالم، 98 درصد است. همچنین توانایی مدل در تمایز بین داده های دسته 1 و دسته 0، 98 درصد است (با توجه به AUC).

مقایسه:

با استفاده از EarlyStopping، دقته کلی مدل تقریباً ثابت مانده است. همچنین درستی مدل در پیش بینی دسته 0، یک درصد افزایش یافته و میتوان از ماتریس درهم ریختگی متوجه شد که این امر به علت کاهش مقدار داده FalseNegative از 202 به 168 است. در مورد Recall برای دسته 0، مقدار کاهش پیدا کرده و این امر به خاطر کاهش مقدار TrueNegative است. در بقیه موارد، معیارهای هر دو راه تقریباً مقادیر برابر دارند.

b) Regression

MSE، میانگین مربع خطای پیش بینی مدل نسبت به داده های هدف است. RMSE، ریشه دوم مقدار MSE است. این معیار، واحد برابر با مقدار خروجی دارد. MAE، میانگین قدر مطلق خطای مدل نسبت به داده های هدف است. واحد این معیار نیز با خروجی یکی است. MSPE، معیاری است که نسبت خطای بزرگی ورودی را حساب می کند. این معیار بر حسب درصد است و خطای صرف نظر از مقیاس خروجی حساب می کند.

جدول 6 . مشخصات مدل LSTM CNN برای مساله Regression

BatchSize	200
-----------	-----

Epochs	200
Optimizer	RMSProp
Loss	MSE

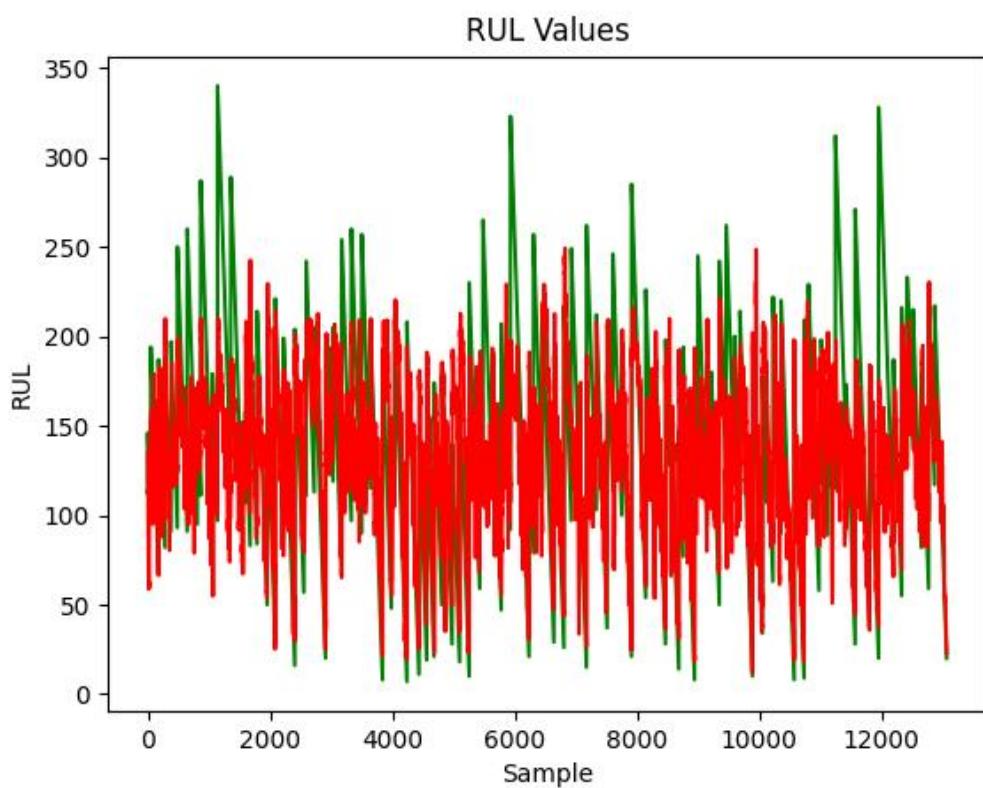
• EarlyStopping بدون

جدول 7. نتایج مدل Regression برای LSTMCNN بدون EarlyStopping

	Value
MSE	2188.33
RMS	46.78
MAE	34.40
MSPE	28.23%

جدول 8. نتایج مدل Regression برای LSTMCNN بدون EarlyStopping برای پنجره آخر

	Value
MSE	654.01
RMS	25.58
MAE	19.01
MSPE	42.23%



شکل ۸. نمودار RUL برای مدل Regression LSTMCNN بدون EarlyStopping (نمودار قرمز مقدار پیش بینی و نمودار سبز مقدار واقعی است)

استفاده از EarlyStopping •

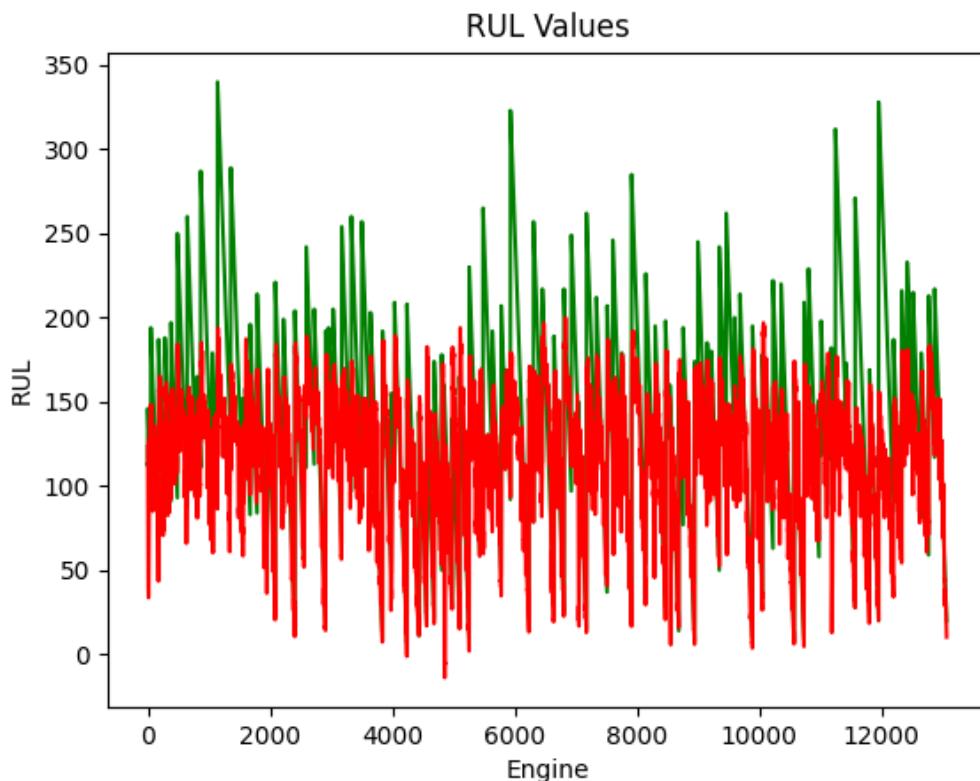
جدول ۱۰. نتایج مدل Regression با LSTMCNN

	Value
MSE	1592.09
RMS	39.94
MAE	29.93
MSPE	26.83

جدول 11. نتایج مدل برای LSTM CNN با Early Stopping

پنجره آخر

	Value
MSE	700.45
RMS	26.46
MAE	20.95
MSPE	47.01



شکل ۹. نمودار RUL برای مدل LSTM CNN با Regression (نمودار قرمز مقدار پیش بینی و نمودار سبز مقدار واقعی است)

مقایسه:

از دو طریق میتوان متوجه شد که مدل در پیش بینی مقادیر کوچک RUL دقیق تر عمل کرده است. مورد اول نمودار مربوط به هر دو مدل است. مقادیر مربوط به RUL های کوچک، همپوشانی بالاتری با مقادیر واقعی نسبت به مقادیر بزرگتر دارد. از طرفی، دقت مدل در پیش بینی مقادیر مربوط به پنجره آخر

(که مقادیر RUL کوچک ترین مقدار است) بالاتر از دقت مدل در پیش بینی همه پنجره هاست. بنابراین این مدل در پیش بینی خروجی سیستم های unhealthy (از کلاس ۰) بهتر عمل می کند.

طبق جدول ۷ و ۱۰، مدل با استفاده از EarlyStopping عملکرد بهتری از خود نشان داده است.

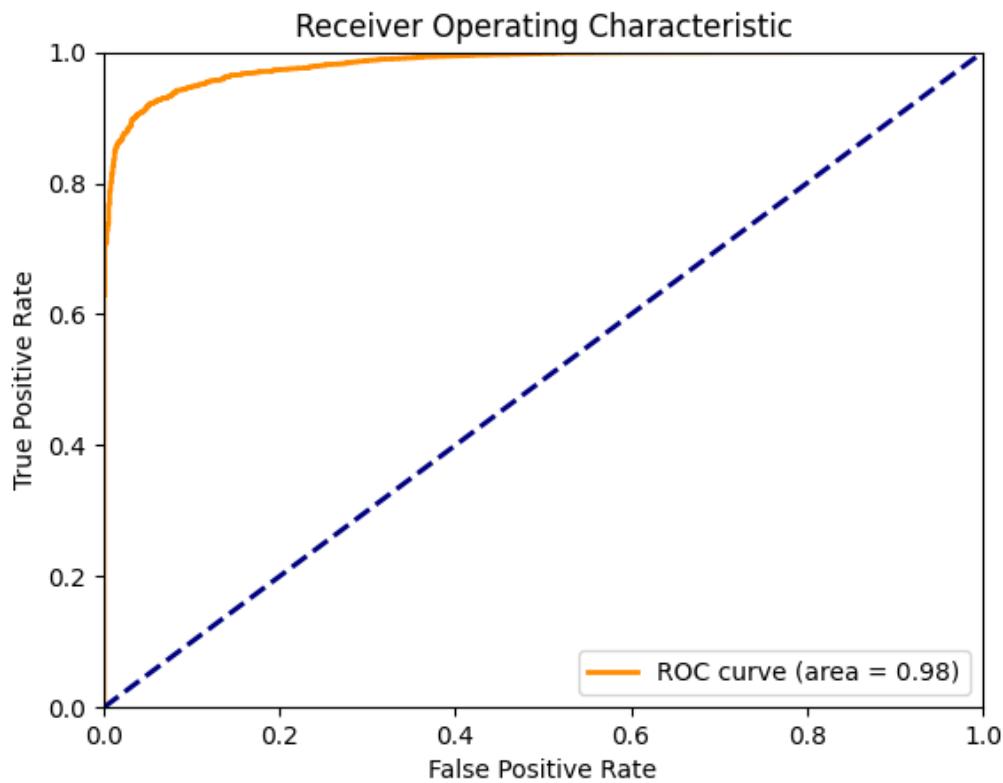
3-2. مقایسه با مدل های پایه

Model Comparison for Convolution Classification

مدل شامل لایه های شبکه LSTM-CNN (به جز لایه های LSTM) است.

Table 12. Results of Convolution Classification Model with EarlyStopping

	Class 0 (Unhealthy)	Class 1 (Healthy)
F1_Score	0.79	0.98
Accuracy	0.96	0.96
Precision	0.79	0.98
Recall	0.79	0.98



شکل ۱۰. نمودار ROC برای مدل Convolution برای مساله Classification با EarlyStopping

جدول ۱۳. ماتریس درهمریختگی برای مدل Convolution برای مساله Classification با EarlyStopping

	Class 0 (Unhealthy)	Class 1(Healthy)
Class 0(Unhealthy)	711	175
Class 1(Healthy)	177	9133

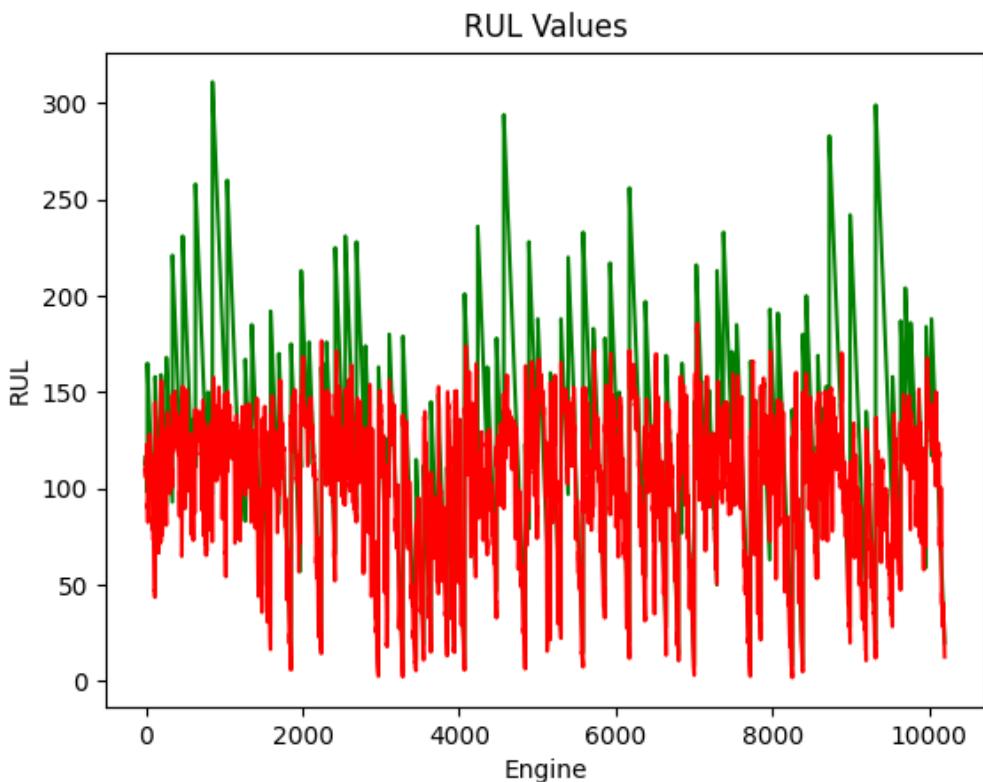
مدل نسبت به مدل LSTM CNN بدون EarlyStopping در تمام موارد دقت کوچکتر یا مساوی کسب کرده است. علت عدمه این موضوع پایین تر بودن هر دو مقدار TrueNegative و TruePositive در مدل Convolution است. همچنین مدل قابلیت تمییز پایین تری بین داده های دو دسته نسبت به مدل LSTM CNN بدون EarlyStopping دارد (مقایسه ROC area).

نسبت به مدل LSTM CNN با EarlyStopping، مدل در تمام مقیاس ها دقت تقریبا مشابه کسب کرده است به جز Recall برای دسته ۰ که دقت بالاتر کسب کرده است. علت این امر، بالاتر بودن مقدار TrueNegative در مدل Convolution است. همچنین قدرت تمییز دو مدل بین داده های دو دسته برابر است.

مدل Convolution برای Regression

جدول ۱۴. نتایج مدل Convolution برای Regression با EarlyStopping

	Value
MSE	2036.71
RMS	45.13
MAE	32.11
MSPE	23.73



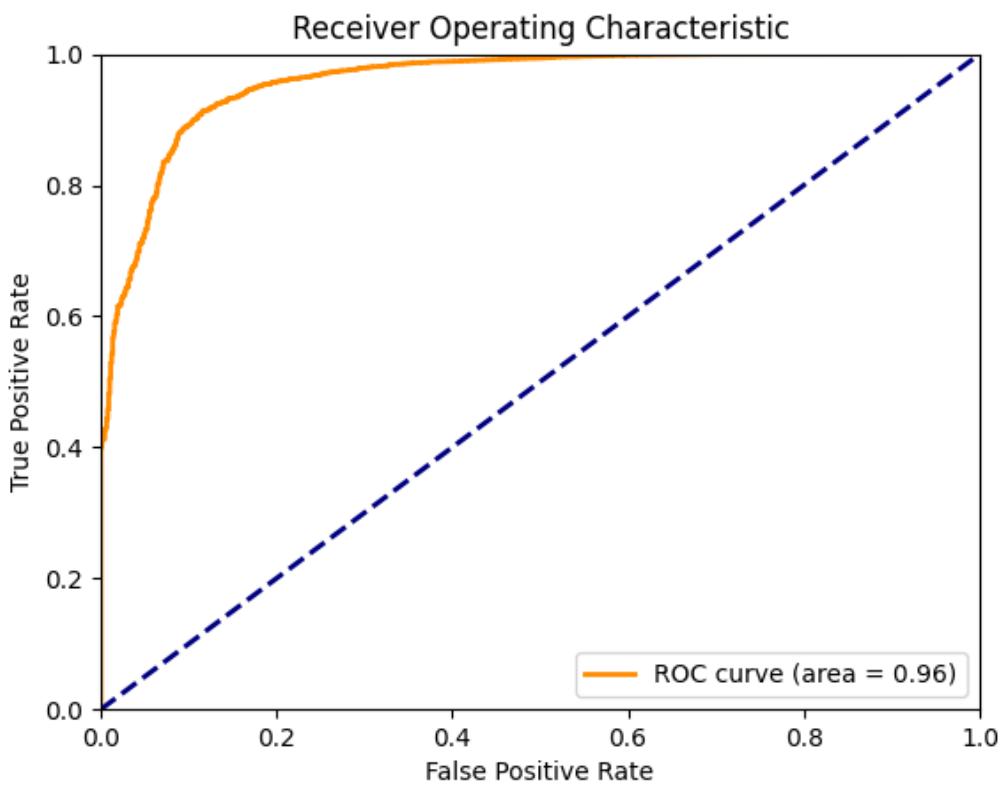
شکل ۱۱. نمودار RUL برای مدل Convolution برای مساله Regression (نمودار قرمز مقدار پیش بینی و نمودار سبز مقدار واقعی است)

نسبت به مدل بهینه تر LSTM-CNN برای regression (مدل با EarlyStopping)، این مدل در تمام معیارها ضعیف تر عمل کرده است. همانطور که از نمودار پیداست، این مدل هم دقت بالاتری در پیش بینی RUL های کوچک تر دارد.

Classification برای LSTM مدل

جدول ۱۵. نتایج مدل Classification برای LSTM با EarlyStopping

	Class 0 (Unhealthy)	Class 1 (Healthy)
F1_Score	0.64	0.97
Accuracy	0.95	0.95
Precision	0.88	0.99
Recall	0.50	0.99



شکل ۱۲. نمودار ROC برای مدل LSTM برای مساله Classification با EarlyStopping

جدول ۱۶. ماتریس درهمریختگی برای مدل LSTM برای مساله Classification با EarlyStopping

	Class 0 (Unhealthy)	Class 1(Healthy)
Class 0(Unhealthy)	448	438
Class 1(Healthy)	58	9252

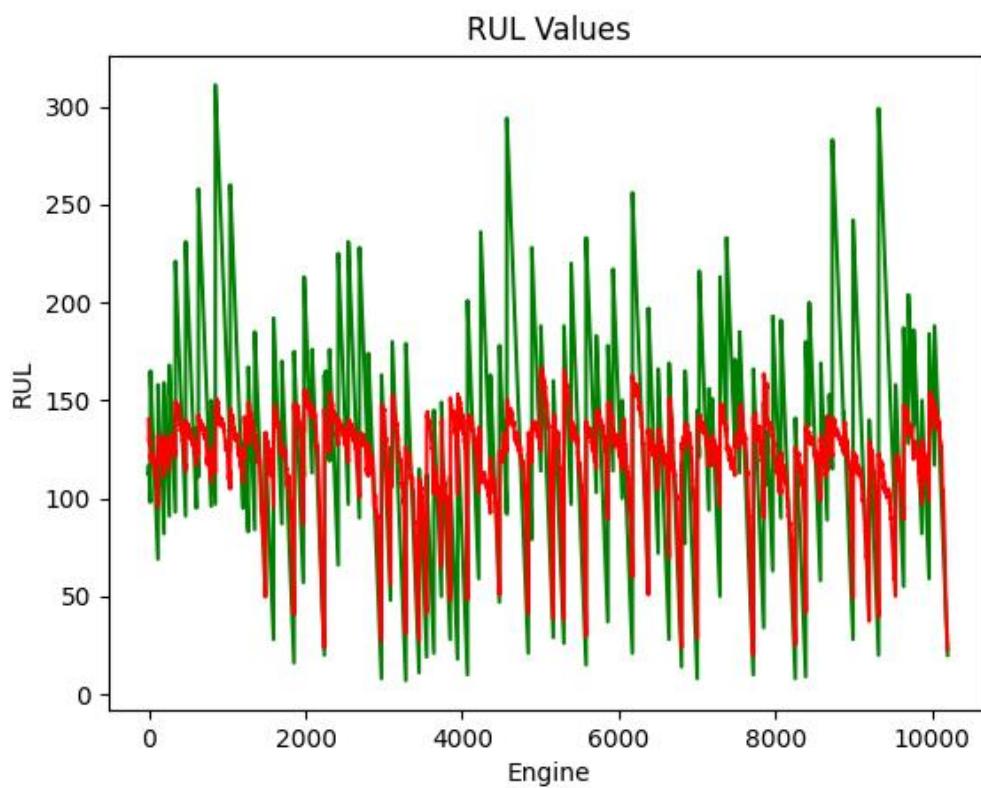
مدل نسبت به هردو مدل LSTMCNN Precision مقدار بالاتر برای دسته 0 و در مورد Precision مقدار پایین تر برای دسته 0 دارد. Recall بالا به علت FalseNegative کوچک تر در Recall است. LSTM پایین به علت Precision کوچک تر در مدل LSTM است. همچنین این مدل نسبت به هردو مدل LSTMCNN، قدرت تمییز پایین تر بین داده های دو دسته دارد (زیرا ROC Curve area 96 درصد دارد).

مدل LSTM برای Regression

مدل LSTM، شامل لایه های شبکه LSTM (به جز لایه های Convolution LSTM CNN) است.

جدول 17. نتایج مدل با Regression LSTM برای EarlyStopping

	Value
MSE	1855.04
RMS	43.07
MAE	32.14
MSPE	31.98



شکل ۱۳. نمودار RUL برای مدل LSTM با Regression EarlyStopping برای مساله (نمودار قرمز مقدار پیش بینی و نمودار سبز مقدار واقعی است)

نسبت به مدل بهینه تر LSTM CNN برای regression (مدل با Early Stopping)، این مدل در تمام معیارها ضعیف تر عمل کرده است. همانطور که از نمودار پیداست، این مدل هم دقیق تر بالاتری در پیش بینی RUL های کوچک تر دارد..

